

Lección 101 de construcción de un data lake: como interpretarlo en AWS

Decisiones de diseño y técnica básicas

25/04/2026



AWS User Group Arequipa



Agenda

- Entendamos un data lake
- 4 Lecciones tipo 101
- Interpretación en AWS
- Conclusión

Entendamos un data lake




El origen de un data lake: en el inicio era data warehouse




El origen de un data lake: pero los años 2000 aparece el cambio real



El origen de un data lake: y hay un problema nuevo



El origen de un data lake: y nace una solución



El origen de un data lake: La definición lógica

"Un Data Lake es un repositorio que almacena datos en su formato original hasta que son necesarios."



El origen de un data lake: La definición técnica

"Un Data Lake es un repositorio que almacena datos en su formato original hasta que son necesarios."

- *Almacenamiento escalable.*
- *Schema-on-read.*
- *Accesibilidad fácil.*



El origen de un data lake: Los servicios de AWS



AWS S3

AWS News Blog

Hadoop Filesystem Using S3

by Jeff Barr | on 11 JAN 2007 | [Permalink](#) | [Share](#)

▶ 0:00 / 0:00

Voiced by Amazon Polly

I blogged about [Hadoop on EC2](#) late last year. In a nutshell, Hadoop is an open source implementation of Google's MapReduce algorithm. MapReduce is a simple and efficient programming model for processing large data sets using a whole bunch of processors (you are supposed to start thinking of [EC2](#) at this point).

Tom White sent me a note this week to inform me that he had implemented a Hadoop file system on top of S3. This file system can be used as a full or partial replacement for HDFS, the [Hadoop Distributed File System](#).


Because bandwidth between EC2 instances and data stored in S3 is not metered or billed, this is a very cost-effective way to process large amounts of data.

If you aren't already running Hadoop on EC2, you can read all about how to do it here.

I would be overjoyed to hear from someone who's used Hadoop on EC2 to do something really cool. Drop me an [email](#).

— Jeff,

Modified 2/1/2021 – In an effort to ensure a great experience, expired links in this post have been updated or removed from the original post.



AWS EC2

El origen de un data lake: la era actual




AWS S3



AWS Athena



AWS S3 Glacier



AWS Glue




AWS Lakeformation

4 lecciones tipo 101




Lección #1: Las capas son sobre organización de datos

- Una capa es sobre gobernar, gestiona y asegurar un conjunto de datos y sus procesos.
- Es una estructura logica abstracta de alto nivel.
- Tiene propiedades:
 - Indivisible en alcance.
 - Una funcionalidad especifica.
 - Independiente pero colaborativo.



Lección #2: gestiona estanques en realidad

- Estanque es la unidad tangible a operar.
- Capa guía al estanque.
- Descripción de un estanque:
 - Estructura organizacional interna.
 - Descriptores alrededor de los datos.
 - Metadatos.
 - Metaprocesos.
 - Criterios de metaprocesos.




Lección #3: Definir las capas es clave

- Conoce el problema, los requerimientos, el ecosistema y realidad empresarial para contextualizar.
- El pensamiento organizacional: calidad, tipo de dato, entidad de negocio y/o transformación.
- Usa los nombres más intuitivos.
- Medallion es un patrón, hay más capas:
 - Aterrizaje.
 - Crudo.
 - Estandarizada.
 - Integración.
 - Consolidada.
 - Consumo.
 - Enriquecido.



Lección #4: Capas verticales y horizontales

- Hay diferentes tipos de capas
- Interacción y funcionalidad *transversal* a los datos.
- Ejemplos:
 - Aterizaje.
 - Metadatos
 - Logs operacionales.
 - Archivamiento.



Interpretación en AWS



Piensa técnico ahora: Servicios fundamentales



AWS CloudTrail
Registro de actividades en infraestructura




AWS S3
Almacenamiento en Sistema de objetos



AWS Athena
Consultas interactivas



AWS IAM
Acceso y permisos en infraestructura



AWS Glue
Procesamiento y descubrimiento de datos

Piensa técnico ahora: visión arquitectural



Piensa técnico ahora: las buenas prácticas técnicas



- Un estanque, un bucket
- Tagging Everywhere
- Estructura de alto hasta bajo nivel.
- Usa el servicio correcto según su uso.
- Optimiza lo mejor posible



- Roles funcionales específicos entre 2 capas.
- Principio del menor privilegio.
- Política basada en ABAC.



- Un database, estanque.
- Una tabla, una "fuente de datos".
- Nombre estratégico.
- Un crawler por "fuente de datos" en el estanque.
- Optimiza los metadatos de descubrimiento.

Conclusión



Un buen trabajo evita
muchos problemas en el
futuro

Síguenme en mis redes



AWS Builder
Center



LinkedIn



Youtube



AWS User Group Arequipa



Lección 101 de construcción de un data lake: como interpretarlo en AWS

Pregunta y respuestas



AWS User Group Arequipa



¡Gracias
totales!