

Lección 101 sobre Data Platform

Aprendiendo a construir un entorno
de datos



Agenda

- Data platform: ¿Porque existe?
- Fundamentos: dinamica negocio - técnico.
- Construyendo con servicios de AWS
- Demos
- Recuerden estos puntos clave





¿Qué es un Data Platform?

¡Depende quien pregunta!

- El negocio: un solución que gestiona los datos para generar valor a la empresa al permitir decision de negocio confiables.






¿Qué es un Data Platform?

¡Depende quien pregunta!

- El negocio: un solución que gestiona los datos para generar valor a la empresa al permitir decision de negocio confiables.
- El técnico: tecnologías integradas para recolectar, procesar, almacenar, gobernar y consumir datos para la empresa.



Data platform: La relación técnico-negocio



Data Platform: Necesidades del negocio

01



Confiable

02




Seguro

03



Recuperable

04



Pueda escalar

Data Platform: Necesidades del negocio

- Hay más como rendimiento, usabilidad o costo eficiencia.
- “Primero que funcione y despues que se optimice”.
- Debes Avanzar ambos AL MISMO TIEMPO.

01




Confiable

02




Seguro

03



Recuperable


04



Pueda escalar


Data Platform: Prácticas del técnico

01




Organización estructural

02



Acoplamiento débil

03



Mapea responsabilidad

04




Registra todo

Data Platform: Prácticas del técnico


- Entiendo como una práctica implementada conecta con una necesidad del negocio.
- Objetivos:
 - Manejo simple.
 - Detección rápida.
 - Cambios controlados y gestionados.

01



Organización
estructural

02



Acoplamiento
débil

03




Mapea
responsabilidad

04



Registra todo

Data platform: Temas técnico fundamentales



Arquitectura de datos

“Organiza los datos en su creación, guardado y consume.”



Seguridad de datos

“Garantizar la disponibilidad y confidencialidad de los datos.”



Calidad de datos

“Garantiza la precisión y completitud de los datos.”




Monitoreo de datos

“Conocer de eventos importantes.”

Data platform: Ayuda memotécnica en AWS



AWS Servicio: Los desafíos alrededor del almacenamiento



Escalamiento de
almacenamiento



Durabilidad y
disponibilidad



Consistencia y
transacciones




Costos
eficiencia

AWS Servicio: S3

Sistema de almacenamiento con objetos

- Servicios Serverless
- Durabilidad del 99.999999999999%
- Max. Tamaño de un objeto: 5TB
- Replicación de objetos entre Buckets.
- Versionamiento de objetos
- S3 Lifecycle policies.
- S3 Table y S3 Vector
- **Caso de uso: data Lake, Búsqueda semantica y RAG**



AWS Servicio: Redshift

Data warehouse en escala


- Serverless y serverfull.
- Escalamiento hasta petabytes.
- Columnas + MPP + Compresion de datos + separación almacenamiento/procesamiento.
- Redshift ML + Sagemaker
- Velocidad en primera consulta con composición.
- Data sharing
- Gestión de cargas de trabajo.
- **Caso de uso: data warehouse y lakehouse.**




AWS Servicios: Los desafíos alrededor del procesamiento




Costos
eficiencia



Escalamiento en
procesamiento



Velocidad de
datos




Organizar los
procesos

AWS Servicio: Glue

Integración de datos


- Servicios Serverless.
- Catalogos: bases de datos + tablas
- Descubrimiento con crawlers.
- Procesamiento diverso
- Workflows: trigger.
- Conectores.
- Registros de calidad de datos.
- **Caso de uso: data lake, data pipeline y lakehouse.**



AWS Servicio: Athena

Analisis de datos interactivo

- Servicios Serverless.
- Consultas con SQL.
- Gestión de cargas de trabajo.
- Guardado de consultas y resultados en S3.
- Costo eficiencia: 1TB x \$5.00
- Query Federadas.
- Seguridad con AWS Lakeformation
- **Caso de uso: data lake, Data Exploration warehouse y data pipeline**



AWS Servicio: Servicios complementarios



AWS Lake Formation

"Gestionar permisos de datos de un data lake"



AWS IAM

"Gestionar permisos entre servicios y usuarios"



AWS CloudTrail


"Audita los cambios en los servicios"



AWS Kinesis Data Stream

"Gestionar el flujo de mensajes streaming"

AWS Servicio: Soluciones populares en datos



Data platform: Entendiendo la demo

El caso del negocio:

- Envío de eventos de ventas continuamente.
- Se quiere generar cada hora un resultado de la ultima hora.
- Los resultados debe ser fácil de consultar por el equipo de analistas de datos, y ser explorados y generados por ellos también.
- Debe costar muy poco la solución.

Data platform: Entendiendo la demo


El caso del negocio:

- Envío de eventos de ventas continuamente.
- Se quiere generar cada hora un resultado de la ultima hora.
- Los resultados debe ser fácil de consultar por el equipo de analistas de datos, y ser explorados y generados por ellos también.
- Debe costar muy poco la solución.

Lo que entendio el técnico:

- Ingesta streaming
- Procesamiento batch (1hr)
- Facil de usar por analista de datos = SQL
- Entorno interactivo de los datos
- **COSTO EFICIENTE = SERVERLESS**

Data platform: Planeando la construcción



TERMINANDO LA DEMO

- Generar una nueva table metrica.
- Guardar la respuesta en data lake.
- Aplicar medidas de gobierno a la table nueva.

Data platform: Demo – Siguientes pasos

Se puede mejorar que cosas

- AWS Kinesis Firehouse o AWS Kinesis Data Stream?
- El problema de los archivos pequeños
- Gestión de permisos para los consumidores
- Automatizarlo con Lambda.

Un Data platform es tan bueno como
tu entendimiento del negocio a
nivel técnico.

Un poco sobre mi

- +5 años como Data engineer. Ahora en TRD.
- Background en ciencias de la computación.
- AWS User Group Leader en Arequipa, Perú.
- AWS Community Builder en Data.
- Amante de los conejos.



Speakers



Santiago Loaiza Giraldo

Soy Senior Cloud Architect, AWS Academy Educator y líder del AWS User Group Manizales....



Jimmy Alejandro Loaiza

Lider TI - Bancolombia

Co-presentador en "Oráculo Secreto"



Carlos Fernando Chicata Farfan

Data Engineer - TRD

Data engineer pasando 4 años: diseñando, implementando y mejorando data pipeline en...



Robert Charca

Co-presentador de la charla

Co-presentador en "Defensa Contra las Artes Oscuras de los data pipelines: hazlo mas..."



Francisco Torres

FinOps - Escala 24x7

En mi rol actual como Cloud Specialist FinOps en Escala 24x7 Inc., contribuyo al diseño,...



¡Conectemos!



[AWS Builder
Center](#)



[YouTube](#)



[LinkedIn](#)



¿Preguntas o dudas?





Lección 101 sobre Data Platform

Aprendiendo a construir un entorno
de datos



AWS Student Builder Group